



一致最小方差无偏估计 UMVUE 的求法归纳

#数理统计 #UMVUE 2021-12-04

一致最小方差无偏估计估计 UMVUE 是参数估计中的重难点内容，也是很多高校考研专业课喜欢考察的问题。但在很多教材中的介绍并不全面，主要问题在于本科生教材浅尝辄止，研究生教材有些晦涩，所以我归纳整理了求解 UMVUE 的背景知识和常用解法，供大家参阅批评。

转载注明出处！

1 一致最小方差无偏估计 (UMVUE)

1.1 均方误差

在参数的点估计中，需要对各个估计量的好坏进行评价。均方误差 (Mean Squared Error) 是在小样本量下对点估计进行评价的常用标准，定义为 $MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2$ ，其中 $\hat{\theta}$ 代表对参数真值 θ 的点估计量。显然，估计的 MSE 越小越好。

对于无偏估计量 $E(\hat{\theta}) = \theta$ ，有

$$\begin{aligned} MSE(\hat{\theta}) &= E[(\hat{\theta} - E\hat{\theta}) + (E\hat{\theta} - \theta)]^2 \\ &= E(\hat{\theta} - E\hat{\theta})^2 + E(E\hat{\theta} - \theta)^2 + 2E[(\hat{\theta} - E\hat{\theta})(E\hat{\theta} - \theta)] \\ &= \text{Var}(\hat{\theta}) \end{aligned}$$

即，无偏估计的均方误差即为其方差。

1.2 一致最小均方误差估计

定义 1 设有样本 X_1, X_2, \dots, X_n ，对待估参数 θ ，有一个估计类，称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 是该估计类中 θ 的一致最小均方误差估计，如果对该估计类中另外一个 θ 的估计 $\tilde{\theta}$ ，在参数空间 Θ 上都有 $MSE_{\theta}(\hat{\theta}) \leq MSE_{\theta}(\tilde{\theta})$

一致最小均方误差估计通常在一个确定的估计类中考虑，若不加限制，一致最小均方误差估计通常是不存在的 ([1]287)。

1.3 一致最小方差无偏估计

当在参数 θ 的无偏估计类中考虑一致最小均方误差估计时，由 (1) 式知，一致最小均方误差估计变为一致最小方差无偏估计。

定义2 对参数估计问题，设 $\hat{\theta}$ 是 θ 的一个无偏估计，如果对另外任意一个 θ 的无偏估计 $\tilde{\theta}$ ，在参数空间 Θ 上都有 $\text{Var}_{\theta}(\hat{\theta}) \leq \text{Var}(\tilde{\theta})$ ，则称 $\hat{\theta}$ 是 θ 的**一致最小方差无偏估计 (Uniform Minimum-Variance Unbiased Estimator)**，记为 **UMVUE**。

定理1 设 $\mathbf{X} = (x_1, x_2, \dots, x_n)$ 是来自总体样本的一个样本， $\hat{\theta} = \hat{\theta}(\mathbf{X})$ 是 θ 的一个无偏估计， $\text{Var}(\hat{\theta}) < \infty$ 。则 $\hat{\theta}$ 是 θ 的 UMVUE 的充要条件是，对任意一个满足 $E(\varphi(\mathbf{X})) = 0$ 和 $\text{Var}(\varphi(\mathbf{X})) < \infty$ 的 $\varphi(\mathbf{X})$ ，都有 $\text{Cov}_{\theta}(\hat{\theta}, \varphi) = 0, \forall \theta \in \Theta$ 。

证明 充分性：对于 θ 的任意一个无偏估计 $\tilde{\theta}$ ，令 $\varphi = \tilde{\theta} - \hat{\theta}$ ，则 $E(\varphi) = 0$ 。于是

$$\begin{aligned}\text{Var}(\tilde{\theta}) &= E(\tilde{\theta} - \theta)^2 \\ &= E[(\tilde{\theta} - \hat{\theta}) + (\hat{\theta} - \theta)]^2 \\ &= E(\varphi^2) + \text{Var}(\hat{\theta}) + 2\text{Cov}(\varphi, \hat{\theta}) \\ &\geq \text{Var}(\hat{\theta})\end{aligned}$$

得证 $\hat{\theta}$ 为 θ 的 UMVUE。必要性证明见参考文献[1]第288页。

2 充分完备统计量

2.1 充分统计量

定义3 设样本 \mathbf{X} 的分布族为 $\{f(\theta, \mathbf{x}), \theta \in \Theta\}$ ， Θ 是参数空间。对于统计量 $\mathbf{T}(\mathbf{X})$ ，若在已知 \mathbf{T} 的条件下，样本 \mathbf{X} 的条件分布与参数 θ 无关，则称 \mathbf{T} 为 θ 的**充分统计量 (Sufficient Statistic)**。

定理2 (因子分解定理) 设 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 是随机向量， $\mathbf{T}(\mathbf{x})$ 是已知函数。则 $\mathbf{T} = \mathbf{T}(\mathbf{X})$ 为充分统计量的充分必要条件是：存在两个函数 $g(\mathbf{T}(\mathbf{x}), \theta)$ 和 $h(\mathbf{x})$ 使得对任意的 θ 和任一组观测值 \mathbf{x} ，有联合概率函数 (简便起见，将连续变量的概率密度函数

和离散变量的概率分布列统称为概率函数，下同)

$$f(\mathbf{x}, \boldsymbol{\theta}) = g(\mathbf{T}(\mathbf{x}), \boldsymbol{\theta})h(\mathbf{x})$$

其中 $g(\mathbf{t}, \boldsymbol{\theta})$ 是 $\mathbf{t}, \boldsymbol{\theta}$ 的函数, $\mathbf{T}(\mathbf{x}) = (T_1(\mathbf{x}), T_2(\mathbf{x}), \dots, T_m(\mathbf{x}))$ 和 $h(\mathbf{x})$ 是 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 的函数.

例1 设 X_1, \dots, X_n 为来自正态总体 $N(\mu, \sigma^2)$ 的 i.i.d 样本, 求 μ, σ^2 的充分统计量.

解 样本的联合概率函数为 $f(\mathbf{x}, \mu, \sigma^2) = (\sqrt{2\pi}\sigma)^{-n} \exp \left[-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \right]$, 整理可得

$$f(\mathbf{x}, \mu, \sigma^2) = (\sqrt{2\pi}\sigma)^{-n} \exp \left[-\frac{\sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2}{2\sigma^2} \right]$$

由因子分解定理 $\mathbf{T} = (\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$ 是参数 (μ, σ^2) 的充分统计量. 进一步整理得

$$f(\mathbf{x}, \mu, \sigma^2) = (\sqrt{2\pi}\sigma)^{-n} \exp \left[\frac{n(\bar{x} - \mu)^2 + (n-1)s^2}{2\sigma^2} \right]$$

说明 (\bar{X}, S^2) 也是参数 (μ, σ^2) 得充分统计量. 事实上 $(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$ 与 (\bar{X}, S^2) 是一一对应的.

定理2 Rao-Blackwell 定理: 假设 $g(\mathbf{X})$ 是 θ 的一个任意估计, $\mathbf{T}(\mathbf{X})$ 是一个充分统计量; 那么 $g(\mathbf{X})$ 相对于给定 $\mathbf{T}(\mathbf{X})$ 的条件期望 $\tilde{g} = E(g(\mathbf{X})|\mathbf{T})$ 是一个比 $g(\mathbf{X})$ 更好的估计量 (至少不差于), 即 $\text{Var}(\tilde{g}) \leq \text{Var}(g)$.

证明 由定义3知 $\tilde{g} = E(g(\mathbf{X})|\mathbf{T})$ 与参数 θ 无关, 故 \tilde{g} 可作为 θ 的估计量, 并可表示为充分统计量 \mathbf{T} 的函数, 记为 $\tilde{g} = \tilde{g}(\mathbf{T})$. 由重期望公式得 $E(\tilde{g}) = E(g)$, 不妨记为 θ_0 .
 $\text{Var}(g) = E[(g - \tilde{g}) + (\tilde{g} - \theta_0)]^2 = E(g - \tilde{g})^2 + E(\tilde{g} - \theta_0)^2 + 2E[(g - \tilde{g})(\tilde{g} - \theta_0)]$
 , 其中

$$\begin{aligned} E[(g - \tilde{g})(\tilde{g} - \theta_0)] &= E\{E[(g - \tilde{g})(\tilde{g} - \theta_0)|\mathbf{T}]\} \\ &= E\{(\tilde{g} - \theta_0)E[(g - \tilde{g})|\mathbf{T}]\} \\ &= E\{(\tilde{g} - \theta_0)[E(g|\mathbf{T}) - E(\tilde{g}|\mathbf{T})]\} \\ &= E[(\tilde{g} - \theta_0)(\tilde{g} - \tilde{g})] \\ &= 0 \end{aligned}$$

故 $\text{Var}(g) = E(g - \tilde{g})^2 + \text{Var}(\tilde{g})$, 则 $\text{Var}(\tilde{g}) \leq \text{Var}(g)$.

由 Rao-Blackwell 定理可知, 若参数得 UMVUE 存在, 则一定是充分统计量或充分统计量的函数.

2.2 完备统计量

定义4 设总体 X 的分布函数是 $F(x; \theta)$, Θ 是参数空间, $\mathbf{T} = \mathbf{T}(\mathbf{X})$ 是基于 X 的样本 X_1, X_2, \dots, X_n 的统计量. 如果对于任何函数 $g(\mathbf{t})$, 条件

$$E_{\theta}g(\mathbf{T}) = 0, \forall \theta \in \Theta$$

蕴涵 $P_{\theta}(g(\mathbf{T}) = 0) = 1 (\forall \theta \in \Theta)$, 则称 $\mathbf{T}(\mathbf{X})$ 是**完全统计量**或**完备统计量** (Complete Statistic).

既是充分的又是完备的统计量称为**充分完备统计量**.

3 指数型分布族

3.1 指数分布族

定义 5 设 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 是随机向量, $h(\mathbf{x}), T_i(\mathbf{x})$ 是 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 的实值函数, $C(\theta), Q_i(\theta)$ 是 θ 的函数. 如果 \mathbf{X} 有联合概率函数

$$f(\mathbf{x}, \theta) = C(\theta) \exp \left[\sum_{i=1}^m Q_i(\theta) T_i(\mathbf{x}) \right] h(\mathbf{x}), \theta \in \Theta$$

则称 \mathbf{X} 服从**指数族分布**, 其分布族称为**指数型分布族**.

3.2 自然形式

定义6 对于上述指数型分布族, 引入新参数

$$\eta_i = Q_i(\theta), i = 1, 2, \dots, m.$$

如果能从 (18) 中解出唯一 $\theta_i = h_i(\boldsymbol{\eta}) (1 \leq i \leq m)$, 其中 $\boldsymbol{\eta} = (\eta_1, \eta_2, \dots, \eta_m)$,

则有 $C(\boldsymbol{\theta}) = \tilde{C}(\boldsymbol{\eta})$, 这就得到指数族分布的自然形式

$$\tilde{C}(\boldsymbol{\eta}) \exp \left[\sum_{i=1}^m \eta_i T_i(\mathbf{x}) \right] h(\mathbf{x})$$

则称 (19) 为**自然指数族**或**标准指数族**, 称

$$\tilde{\Theta} = \{\boldsymbol{\eta} | \boldsymbol{\eta} = (Q_1(\boldsymbol{\theta}), Q_2(\boldsymbol{\theta}), \dots, Q_m(\boldsymbol{\theta})), \boldsymbol{\theta} \in \Theta\}$$

为**自然参数空间**或**标准参数空间**.

例2 证明 $\text{Ga}(\alpha, \lambda)$ 的样本分布服从指数型分布, 并写出其自然形式.

解 记 $\Theta = (\theta_1, \theta_2) = (\alpha, \lambda)$, 则样本随机变量 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 的联合密度为

$$\begin{aligned} f(\mathbf{x}, \Theta) &= \frac{\lambda^{n\alpha}}{\Gamma^n(\alpha)} \exp \left[(\alpha - 1) \sum_{i=1}^n \ln x_i - \lambda \sum_{i=1}^n x_i \right] \\ &= C(\Theta) \exp [Q_1(\boldsymbol{\theta})T_1(\mathbf{x}) + Q_2(\boldsymbol{\theta})T_2(\mathbf{x})] h(\mathbf{x}) \end{aligned}$$

其中 $C(\Theta) = \frac{\theta_2^{n\theta_1}}{\Gamma^n(\theta_1)}$, $Q_1(\boldsymbol{\theta}) = \theta_1 - 1$, $Q_2(\boldsymbol{\theta}) = -\theta_2$, $h(\mathbf{x}) = 1$. (θ_1, θ_2) 的参数空间是

$$\Theta = \{\boldsymbol{\theta} = (\theta_1, \theta_2) | \theta_1 > 0, \theta_2 > 0\}.$$

所以 \mathbf{X} 服从指数分布. 下面取 $\eta_1 = Q_1(\boldsymbol{\theta}) = \theta_1 - 1$, $\eta_2 = Q_2(\boldsymbol{\theta}) = -\theta_2$, 则唯一解出

$$\theta_1 = \eta_1 + 1, \theta_2 = -\eta_2, \tilde{C}(\boldsymbol{\eta}) = \frac{(-\eta_2)^{n(\eta_1+1)}}{\Gamma^n(\eta_1 + 1)}$$

所以 \mathbf{X} 分布的自然形式为

$$\tilde{C}(\boldsymbol{\eta}) \exp [\eta_1 T_1(\mathbf{x}) + \eta_2 T_2(\mathbf{x})] h(\mathbf{x})$$

且自然参数空间为

$$\tilde{\Theta} = \{\boldsymbol{\eta} = (\eta_1, \eta_2) | \eta_1 > -1, \eta_2 < 0\},$$

定理3 如果 \mathbf{X} 的概率分布族能写成指数分布的自然形式 (19), 且自然参数空间 $\tilde{\Theta}$ 有内

点, 则

$$\mathbf{T}(\mathbf{X}) = (T_1(\mathbf{X}), T_2(\mathbf{X}), \dots, T_m(\mathbf{X}))$$

是 $\boldsymbol{\theta}$ 和 $\boldsymbol{\eta}$ 充分完备统计量.

证明 由因子分解定理易证 $\mathbf{T}(\mathbf{X})$ 为充分统计量, 完全性的证明参见参考资料[2]第 80 页.

例 3 对于正态分布 $\{N(0, \sigma^2) : \sigma \in \mathbb{R}^+\}$, 证明统计量 X_1 不是完备统计量, 而 $T = \sum_{i=1}^n X_i^2$ 是完备统计量.

解 $E_\sigma(X_1) = 0$ 而 $P_\sigma(X_1 = 0) = 0 \neq 1 (\forall \sigma \in \mathbb{R}^+)$, 故 X_1 不是完备统计量.

$X_i/\sigma \sim N(0, 1)$, 故 $T/\sigma^2 \sim Ga(\frac{n}{2}, \frac{1}{2})$, 因此 $T \sim Ga(\frac{n}{2}, \frac{1}{2\sigma^2})$, 由例 1 知, \mathbf{X} 服从指数型分布族, 且其自然参数空间有内点, 故由定理 3, T 为充分完备统计量, 证必.

4 Lehmann–Scheffé 定理

定理 4 Lehmann–Scheffé 定理 设 $\mathbf{T} = \mathbf{T}(\mathbf{X})$ 是充分完备统计量, 若 $\hat{g}(\mathbf{X})$ 是 $h(\boldsymbol{\theta})$ 的方差有限的无偏估计, 即

$$E_{\boldsymbol{\theta}} \hat{g}(\mathbf{X}) = h(\boldsymbol{\theta}), \text{Var}_{\boldsymbol{\theta}}(\hat{g}(\mathbf{X})) < \infty, \forall \boldsymbol{\theta} \in \Theta,$$

则条件数学期望

$$\eta(\mathbf{T}) = E[\hat{g}(\mathbf{X})|\mathbf{T}]$$

是 $h(\boldsymbol{\theta})$ 的唯一的 UMVUE. 证明见参考文献[3]103页

5 Cramer-Rao 不等式

定理 5 Cramer-Rao 不等式 设总体分布 $f(x, \theta)$, X_1, \dots, X_n 是来自该总体的简单样本, $T = T(X_1, \dots, X_n)$ 是 $g(\theta)$ 的任一个无偏估计, $g'(\theta) = \frac{\partial g(\theta)}{\partial \theta}$ 存在, 且对 Θ 中一切 θ , 对

$$g'(\theta) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \dots, x_n) \prod_{i=1}^n p(x_i, \theta) dx_1 \cdots dx_n,$$

的微商可在积分号下进行，即

$$g'(\theta) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \cdots, x_n) \frac{\partial}{\partial \theta} \left(\prod_{i=1}^n p(x_i, \theta) \right) dx_1 \cdots dx_n.$$

则有

$$\text{Var}(T) \geq \frac{[g'(\theta)]^2}{nI(\theta)}$$

其中 $I(\theta) = E\left[\frac{\partial}{\partial \theta} \ln f(x, \theta)\right]^2$ 为费希尔信息量， $\frac{[g'(\theta)]^2}{nI(\theta)}$ 称为参数估计的 C-R 下限。证明详见参考文献[1]291页。

(31) 式中若等号成立则称 T 是 $g(\theta)$ 的有效估计，有效估计一定是 UMVUE。

6 UMVUE 的求法

根据 Rao-Blackwell 定理，UMVUE 若存在一定是基于充分统计量的估计。故寻找 UMVUE 可以利用因子分解定理寻找充分统计量，然后对充分统计量进行无偏修正，得到可能的 UMVUE，最后可以利用 UMVUE 的充要条件 (定理1)、Lehmann-Scheffé 定理、Cramer-Rao 不等式等方法说明其方差一致最小。

下面通过例题说明求 UMVUE 的具体思路。

例4 设 X_1, \cdots, X_n 为来自正态总体 $N(\mu, \sigma^2)$ 的 i.i.d 样本，求 μ, σ^2 的 UMVUE。

解法1 由例1知， (\bar{X}, S^2) 是 (μ, σ^2) 的充分统计量。 $E(\bar{X}) = \mu, E(S^2) = \sigma^2$ 均为无偏估计，且为充分统计量的函数。令 $E(\varphi(\mathbf{X})) = 0$ ，即

$$\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \varphi(x_1, \cdots, x_n) \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} dx_1 \cdots dx_n =$$

两边对 μ 求导，得

$$\begin{aligned} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \varphi(x_1, \cdots, x_n) \sum_{i=1}^n (x_i - \mu) \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} dx_1 \cdots dx_n \\ \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \varphi(x_1, \cdots, x_n) \bar{x} f(\mathbf{x}, \theta, \sigma^2) dx_1 \cdots dx_n \\ \text{Cov}(\varphi, \bar{X}) \end{aligned}$$

由定理1知, \bar{X} 是 μ 的 UMVUE.

同理, 式 (32) 俩边对 σ^2 求导, 得到 $\text{Cov}(\varphi, S^2) = 0$, 证得 S^2 是 σ^2 的 UMVUE.

解法2 记 $\mathbf{T} = (T_1(\mathbf{X}), T_2(\mathbf{X})) = (\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$ 样本的联合密度函数为

$$\begin{aligned} f(\mathbf{x}, \theta, \sigma^2) &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right] \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left(-\frac{n\mu^2}{2\sigma^2} \right) \exp \left[\frac{\mu T_1(\mathbf{x})}{\sigma^2} - \frac{T_2(\mathbf{x})}{2\sigma^2} \right] \\ &= C(\boldsymbol{\Theta}) \exp [Q_1(\boldsymbol{\theta})T_1(\mathbf{x}) + Q_2(\boldsymbol{\theta})T_2(\mathbf{x})] h(\mathbf{x}) \end{aligned}$$

其中, $\boldsymbol{\theta} = (\theta_1, \theta_2) = (\mu, \sigma^2)$, $h(\mathbf{x}) = 1$.

取 $\eta_1 = Q_1(\boldsymbol{\theta}) = \frac{\theta_1}{\theta_2}$, $\eta_2 = Q_2(\boldsymbol{\theta}) = \frac{-1}{2\theta_2}$, 唯一解出 $\theta_1 = \frac{-\eta_1}{2\eta_2}$, $\theta_2 = \frac{-1}{2\eta_2}$, 带入 $C(\boldsymbol{\theta})$ 得到 $\tilde{C}(\boldsymbol{\eta})$. 所以 \mathbf{X} 的分布族为指数型分布族且有自然形式, 自然参数空间为

$$\tilde{\Theta} = \{\boldsymbol{\eta} = (\eta_1, \eta_2) | \eta_1 \in (-\infty, \infty), \eta_2 < 0\}$$

由定理3知, $\mathbf{T} = (\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$ 是 $\boldsymbol{\Theta} = (\mu, \sigma^2)$ 的充分完备统计量, 基于该统计量构造 μ, σ^2 的无偏估计 \bar{X}, S^2 . 显然 \bar{X}, S^2 都可以表示为 \mathbf{T} 的函数, 故由 Lehmann–Scheffé 定理 $\bar{X} = E(\bar{X}|\mathbf{T})$ 和 $S^2 = E(S^2|\mathbf{T})$ 分别为 μ 和 σ^2 的 UMVUE.

上例中, 分布族为指数型分布族, 使用定理3确定充分完备统计量是方便的, 然后使用 Lehmann–Scheffé 定理说明 UMVUE. 对于非指数族分布, 可以尝试使用因子分解定理和定义4说明充分性和完备性.

例5 设 X_1, \dots, X_n 为来自均匀样本分布 $U(0, \theta), \theta > 0$ 的 i.i.d 样本, 求 θ 的 UMVUE.

解 样本的联合概率分布为 $f(\mathbf{x}, \theta) = \frac{1}{\theta^n} I_{\{0 < x_{(n)} < \theta\}}$, 其中 $X_{(n)} = \max\{\mathbf{X}\}$ 为次序统计量. 根据因子分解定理, $T = X_{(n)}$ 为充分统计量. T 的概率密度函数为 $f(t, \theta) = n \frac{t^{n-1}}{\theta^n} I_{\{0 < x_{(n)} < \theta\}}$. 则 $E(T) = \frac{n}{n+1} \theta$, 可得 $\frac{n+1}{n} T$ 为 θ 的无偏估计, 记为 $\hat{\theta}(T)$. 设 $E(g(T)) = 0$, 即

$$\int_0^\theta g(T)n \frac{t^{n-1}}{\theta^n} dt = 0$$

$$\int_0^\theta g(T)t^{n-1} dt = 0$$

两边对 θ 求导, 得 $g(\theta) = 0$, 由定义4知 T 为完备统计量. $\hat{\theta}(T) = E(\hat{\theta}(T)|T)$, 由 Lehmann–Scheffé 定理, $\hat{\theta} = \frac{n+1}{n}X_{(n)}$ 为 θ 的 UMVUE.

相对于以上解法, 估计的 C-R 下限的计算是简单而直接的, 所以对于某估计我们可以先验证它的方差是否达到 C-R 下限, 一旦达到 C-R 下限则立即说明该估计为 UMVUE.

例6 设总体为指数分布 $Exp(1/\theta)$, 求参数 θ UMVUE.

解 先计算费希尔信息量 $I(\theta) = E\left[\frac{\partial}{\partial\theta}\ln f(x, \theta)\right]^2 = \frac{1}{\theta^2}$, 则 θ 的 C-R 下限为 $\frac{1}{nI(\theta)} = \frac{\theta^2}{n}$. 对于 θ 的无偏估计量 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, 其方差为 $\text{Var}(\bar{X}) = \frac{\theta^2}{n}$ 达到 C-R 下限, 故为有效估计, 则为 UMVUE.

通过以上例题, 总结 UMVUE 的求法思路.

1. 首先应明确, 并不是所有的参数都有 UMVUE.
2. 根据 Rao–Blackwell 定理, 若 UMVUE 存在则一定是基于充分统计量的, 故应先寻找参数的充分统计量.
3. 确定待证明的统计量, 一般基于充分统计量构造, 然后进行无偏修正.
4. 证明选择的统计量为 UMVE. 具体地,
 1. 首先考虑 C-R 下限, 因为该方法计算相对简单, 一旦估计的方差达到下限, 则立即说明其为 UMVUE. 但应注意方差达到 C-R 下限是 UMVUE 的充分不必要条件.
 2. 由于指数族分布的优良性质, 整理联合概率函数, 证明其为指数族分布且有自然形式, 并写出自然参数空间, 使用定理3说明 UMVUE.
 3. 若分布族不是指数族分布, 则考虑使用完备统计量的定义说明完备性(例5), 然后利用 Lehmann–Scheffé 定理说明 UMVUE.
 4. 使用 UMVUE 的充分必要条件 (定理1), 对 $E(\varphi) = 0$ 两边求导, 整理得到 $\text{Cov}(\varphi, T) = 0$ 来证明.

5. 对于某些特殊的情况可以使用定义法直接说明其方差一致最小，但一般比较困难。
6. 若以上方法均无法证明，则考虑更换估计量，或者估计的 UMVUE 不存在。

参考文献

- [1] 茆诗松, 程依明, 濮晓龙. 概率论与数理统计教程. 3版. 北京: 高等教育出版社, 2019.
- [2] 陈希孺. 数理统计引论. 北京: 科学出版社, 1981.
- [3] 韦来生. 数理统计. 北京: 科学出版社, 2015.
- [4] 周伟萍, 关于一直最小方差无偏估计的教学思考, 高师理科学刊, 2013,33(06)
- [5] Charles Elkan, Rao-Blackwell Theorem: Intuition, Lemmas and Start of Proof



“又摘桃花换酒钱”

♥ 喜欢作者

← 上一篇

「篮球裁判手势挑战」小程序发布

下一篇 →

使用 Web 前端技术开发一个 Wallpaper Engine 壁纸

#数理统计 #UMVUE

[机器学习基础-“逻辑”回归\(logistic regression\)的数学原理](#)

[机器学习基础-BP\(Error Back Propagation\)算法的数学原理](#)

0 条评论

未登录用户 



说点什么

 支持 Markdown 语法

使用 GitHub 登录

预览

来做第一个留言的人吧!

海内存知己 天涯若比邻

朋友

 [Lei's Research](#)

 [Yangtian's blog site](#)

 [咕咕](#)

 [申请友链](#)

账号

[hooozen](#)

 [谁在胡言乱语](#)

 [Mundooo](#)

联系

 Hozen@live.com

[hozen.site](https://www.hozen.site) | 由 [Hexo](#) 及  致远 驱动