

7.6 参数的有效个数

“参数个数”的概念可以推广，特别是推广到在拟合中使用了正则的模型中。假设我们将输出 y_1, y_2, \dots, y_N 放进向量 \mathbf{y} 中，类似地对预测值进行同样操作得到 $\hat{\mathbf{y}}$ 。于是我们可以将线性拟合模型写成：

$$\hat{\mathbf{y}} = \mathbf{S}\mathbf{y} \quad (7.31)$$

其中 \mathbf{S} 为依赖于输入向量 x_i 但不依赖于输出 y_i 的 $N \times N$ 阶矩阵。线性拟合方法包括在原始特征或在导出基的集合中运用的线性回归，以及采用平方收缩的光滑化方法，比如岭回归和三次光滑样条。则 **有效参数个数 (effective number of parameters)** 定义为：

$$\text{df}(\mathbf{S}) = \text{trace}(\mathbf{S}) \quad (7.32)$$

是 \mathbf{S} 对角元之和（也被称作 **有效自由度 (effective degrees-of-freedom)**）。注意到如果 \mathbf{S} 为投影到由 M 个特征张开的 **基础集 (basis set)** 上的正交投影矩阵，则 $\text{trace}(\mathbf{S}) = M$ 。事实证明 $\text{trace}(\mathbf{S})$ 恰巧是 C_p 统计量（式 7.26）替换掉 d 作为参数个数的那个值。

如果 \mathbf{y} 是从加性误差模型 $Y = f(X) + \epsilon$ 中产生的， $\text{Var}(\epsilon) = \sigma_\epsilon^2$ ，则可以证明 $\sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i) = \text{trace}(\mathbf{S})\sigma_\epsilon^2$ ，导出了更一般的定义

$$\text{df}(\hat{\mathbf{y}}) = \frac{\sum_{i=1}^N \text{Cov}(\hat{y}_i, y_i)}{\sigma_\epsilon^2} \quad (7.33)$$

（练习 7.4 和 7.5）第 5.4.1 节给出了在光滑样条情形下 $\text{df} = \text{trace}(\mathbf{S})$ 更直观的定义。

对于像神经网络的模型，我们用系数衰减（正则化） $\alpha \sum_m w_m^2$ 来最小化误差函数 $R(w)$ ，有效参数个数有如下形式：

$$\text{df}(\alpha) = \sum_{i=1}^M \frac{\theta_m}{\theta_m + \alpha} \quad (7.34)$$

其中 θ_m 是 Hessian 矩阵 $\partial^2 R(w) / \partial w \partial w^T$ 的特征值。如果我们对解的误差函数做二次近似便可由式 (7.32) 导出式 (7.34) (Bishop, 1995^[1])。

[1] Bishop, C. (1995). Neural Networks for Pattern Recognition, Clarendon Press, Oxford.